

项目中期报告

程铭 517021910750, 张弛 517021910658

现阶段进展

1. 完成数据预处理工作

数据集介绍

我们所采用的数据为近期更新的非小细胞肺癌患者CT图像数据集：NSCLC-Radiomics。经过我们的调查研究，现有论文未采用该数据集进行机器学习训练。该数据集来自共422位的肺癌患者，每位患者包括80~200张数目不等的CT图像，且每张图像分别来自不同位置的肺部切片。由于数据集格式较为复杂，因此对数据集进行正确的预处理十分重要。

dcm格式到jpg格式的转换

为方便将数据集作为输入进行模型训练等后续操作，将数据集从dcm格式（医学图像格式）转换为jpg格式十分重要，我们通过编写`prepare_training_data.py`成功实现这一步骤。此外，由于原图像中肺部位置各不相同（e.g.偏左、偏上等），经过此处理使各图像肺部位置居中、且图片大小统一。

2. 完成数据加强工作

为加强模型的鲁棒性、提升模型训练精度、使模型更好地提取图像特征，我们对数据集进行了如下数据加强工作：

数据随机旋转

为使得模型不受输入图像的角度所影响，增强模型的鲁棒性和泛化能力，我们采用一定概率 p_1 随机旋转输入图像，且旋转角度为 $0 \sim \theta^*$ 之间的随机数 θ （ θ^* 为预先设定的旋转角度上限）。因此经过此处理，每张图片与横轴所成的角度为 $\theta = f(p_1, \theta^*)$ ，其中 f 为随机函数。若设总图片数量为 n ，经过此处理后，总图片数量为 $n_1 = n + p_1 n = (1 + p_1)n$ 。在增加数据多样性的同时也增加了数据量，一定程度上提升了训练精度。

数据随机翻转

考虑到肺部图像的翻转对称性，为使得模型不受图像对称性的影响，我们采用一定概率 p_2 左右翻转图片。经过第一步处理，总图片数量为 n_1 ，经过此处理后，总图片数量为 $n_2 = n_1 + p_2 n_1 = (1 + p_2)n_1$ ，在增加数据多样性的同时也增加了数据量，一定程度上提升了训练精度。

数据放大截取

考虑到原数据大小为 512×512 个像素点，我们以一定概率 p_3 随机放大图像，且放大倍数为 $0 \sim K$ 之间的随机数 k ，然后再截取与原数据相同大小（ 512×512 ）。经过此处理，模型可以更好地学习到图像的特征。经过上述两个步骤的处理，总图片数量为 n_2 ，再经过此步骤处理，总图片数量为 $n_3 = n_2 + p_3 n_2 = (1 + p_3)n_2$ 。

因此，经过上述三步骤的数据加强工作，总数据量由 n 变为 $(1 + p_1)(1 + p_2)(1 + p_3)n$ ，数据量增加、数据多样性增加，在提升模型精度的同时也提升了模型的鲁棒性。

数据均值归一化

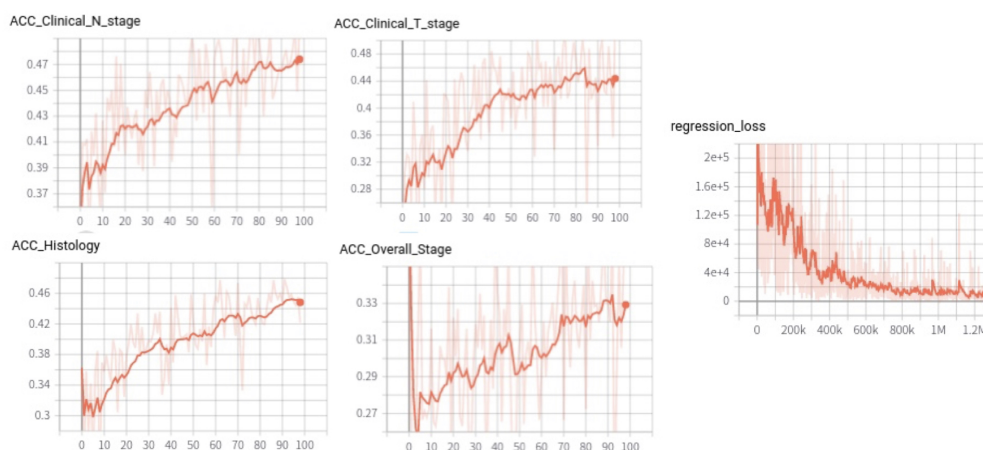
与此同时，为更好地提取、学习数据的特征，避免由数据不同位置的影响导致模型判断能力的下降，我们对所有数据进行了均值归一化处理（`mean_normalize`）。经过此步骤，可以保证模型更好地学习特征，且不会因为原数据的不同而影响最终的训练结果。

3. 成功搭建模型框架

为实现整个项目代码的规范性以及实现模块化编程思想，我们成功搭建了整体的模型框架`models`文件夹。通过调用文件夹中的各文件便可进行模型的训练，大大简化了模型训练部分的代码。与此同时，我们从每位患者的CT图像（约80~200不等）中随机取出两张图像作为测试集，其余图片作为训练集进行模型训练。

4. 成功运行baseline模型

经过上述数据预处理、数据增强、模型框架搭建等操作，我们编写了baseline模型代码并成功运行。下图为baseline模型的训练结果图：



由上述结果可知，对于分类任务，对于所输出的四个类别（左边4张图），随着迭代次数的增加，分类精度都逐渐提升，因此模型表现良好；对于回归任务（预测患者存活时间），随着迭代次数的增加，损失逐渐减小、最终收敛。因此，所搭建的baseline模型可以成功地运行该数据集。当然，baseline模型的输出精度较低，后续还需要搭建更为精确的模型，提升分类精度和回归精度。

后期工作安排

网络结构表现的对比与测试

baseline的网络结构为最简单的卷积+全连接的网络结构，实验结果表明baseline的简单网络存在模型训练收敛速度慢，模型表现潜力较低等缺点。而目前神经网络有多种新颖的结构，且各有不同的特性与潜能。例如`Inception block`, `Residual block`, `ResNet block`, `Xception block`, `Channel boost block`等等，我们希望对比这些结构对于医疗图像分类预测任务的表现，并分析网络结构带来的影响。

FCCM网络模型的设计

基于对基础的网络结构的研究与分析，挑选出适合我们非小细胞肺癌CT图像分类预测任务的网络基础结构，并搭建我们的网络模型。确认网络结构后，我们会提出完整的训练方案，并对于网络的使用代码进行包装，实现基于多张CT图像对病人的病情进行分析与未来预测。